

Franck Picard - Complément Contributions

Laboratoire de Biologie et Modélisation de la Cellule (LBMC), ENS de Lyon • franck.picard@ens-lyon.fr • [franckpicard.github.io](https://github.com/franckpicard)

Etude des origines de réplication du génome humain

Mes travaux sur les origines de réplication de l'ADN ont notamment porté sur le rôle des G-quadruplexes (G4), des structures secondaires de l'ADN enrichies aux sites d'initiation de la réplication. Si leur présence était connue pour être nécessaire à l'initiation, un G4 isolé ne suffit pas à caractériser une origine active. En collaboration avec M.-N. Prioleau (IJM) et L. Duret (LBBE), nous avons cherché à mieux comprendre leur rôle et leurs interactions avec l'organisation de la chromatine.

En combinant approches expérimentales sur une origine modèle et analyses à l'échelle du génome, nous avons montré que deux motifs G-quadruplexes positionnés sur le même brin d'ADN sont associés à la formation d'une région dépourvue de nucléosomes et caractérisent les origines de réplication les plus actives. Nous avons ainsi identifié un nouvel élément génétique fonctionnel impliqué dans l'organisation de la chromatine et la régulation de l'initiation de la réplication chez les vertébrés. Ce travail a été publié dans Nature Communications en 2023 et marque l'aboutissement de cet axe de recherche.

Réduction de dimension pour données fonctionnelles.

Mes travaux sur les données de séquençage m'ont conduit à m'intéresser à la modélisation de signaux observés le long du génome. L'émergence de nouvelles technologies permettant d'observer des collections de profils sur plusieurs cellules a fait apparaître une nouvelle question : comment représenter la variabilité entre ces fonctions ? Nous nous sommes tournés vers l'analyse en composantes principales fonctionnelle. Pour un processus fonctionnel Y , de fonction de covariance $K(s, t)$, l'ACP repose sur l'analyse spectrale de l'opérateur de covariance

$$\Gamma(f)(\cdot) = \int_0^1 K(s, \cdot) f(s) ds,$$

dont les fonctions propres définissent les composantes principales. En pratique, ces fonctions ne sont cependant jamais observées continûment, mais sur une grille discrète, et leur estimation nécessite généralement une étape de projection sur une base fonctionnelle. L'estimation comporte donc deux sources d'erreur : une erreur de discrétisation et une erreur liée à la projection ou au lissage.

Avec V. Rivoirard et A. Roche, dans le cadre de la thèse de R. Belhakem (soutenue en 2022), nous avons caractérisé pour la première fois l'impact conjoint de ces deux sources d'erreur sur l'estimation de l'opérateur de covariance et de ses fonctions propres. Pour (n) courbes observées sur une grille commune de taille (p) , nous avons notamment obtenu une erreur d'approximation de l'ordre de

$$n^{-1} + p^{-2\alpha},$$

où α caractérise la régularité du processus. Cette décomposition met en évidence une double asymptotique : une composante paramétrique gouvernée par le nombre de courbes et une composante non paramétrique liée à la discrétisation des fonctions. Nous avons établi les vitesses minimax correspondantes et identifié une transition de phase déterminant les régimes dans lesquels la discrétisation affecte ou non la qualité de l'estimation. Nous avons également montré que, pour un choix approprié de base de projection, notamment une base d'histogrammes, l'estimateur naïf obtenu sans régularisation supplémentaire atteint la vitesse minimax. Ce résultat apporte un éclairage théorique sur une question importante en analyse fonctionnelle : il montre qu'un lissage préalable n'est pas nécessairement requis pour obtenir une estimation optimale des composantes principales. Ces travaux ont été publiés dans Scandinavian Journal of Statistics. Ces résultats sont prolongés dans la thèse de N. Bourarach (2022–2026, Université Paris-Dauphine), co-encadrée avec V. Rivoirard et A. Roche, avec notamment l'objectif d'étendre cette analyse à d'autres classes de régularité.

Déconvolution de processus ponctuels avec erreur de localisation

Nos travaux sur les origines de réplication ont mis en évidence leur association avec différents éléments génétiques et épigénétiques, notamment les îlots CpG, les G-quadruplexes et plusieurs marques de chromatine. L'étude de ces associations repose sur la comparaison de positions génomiques issues notamment de données ChIP-seq. Or ces positions sont généralement fournies sous forme d'intervalles et sont donc observées avec une incertitude de localisation, dont la loi est rarement connue précisément. Pour prendre en compte cette incertitude, nous avons proposé de modéliser la position observée d'un événement par

$$Y = X + E, \quad E \sim \mathcal{U}[-\eta, \eta],$$

où X désigne sa position réelle et η caractérise l'incertitude de localisation. Si X est un processus de Poisson d'intensité λ_X , l'intensité observée vérifie alors

$$\lambda_Y = \lambda_X \star f_E.$$

Le problème statistique consiste à reconstruire l'intensité λ_X du processus latent à partir des positions bruitées. En collabora-

tion avec A. Bonnet, V. Rivoirard et C. Lacour, nous avons développé un estimateur à noyau de λ_X adapté à ce problème de déconvolution, avec sélection adaptative de la fenêtre par une procédure de Goldenshluger–Lepski. Une difficulté importante réside dans la calibration de cette procédure, qui comporte plusieurs hyperparamètres inconnus. Nous avons appliqué cette méthode aux origines de réplication, dont les positions sont mesurées avec une incertitude liée à la largeur des pics d’initiation. L’intensité reconstruite restitue une organisation des origines en domaines de taille inférieure au mégabase, en accord avec leur organisation biologique connue. Ce travail apporte ainsi une solution statistique à un problème général de processus ponctuels observés avec erreur de localisation. Il a été publié dans le *Journal of Machine Learning Research* [2].

Modélisation et analyse des données -omiques pour cellules uniques

Contexte. Les techniques de séquençage à haut débit associées à de nouvelles méthodes biomoléculaires nous permettent désormais de travailler à l’échelle d’une cellule unique pour les données omiques. Jusqu’à présent, ce type de technologies était limité à l’analyse d’individus, de tissus ou de groupes de cellules nécessaires pour l’obtention des quantités de matériel génétique suffisantes pour un séquençage. Nous n’avions donc accès qu’à une information moyennée sur un ensemble de cellules, et surtout la variabilité inter-cellulaire n’était pas quantifiable. Mais ces nouvelles technologies soulèvent de nouveaux défis méthodologiques. Depuis 2019 cette thématique est devenue progressivement ma thématique principale, avec deux axes méthodologiques principaux: les nouvelles techniques d’inférence pour l’analyse différentielle et la réduction de dimension.

Réduction de dimension non linéaire

La réduction de dimension est une étape centrale de l’analyse de données de grande dimension, notamment pour la visualisation. Les méthodes non linéaires comme t-SNE et UMAP, devenues standards pour l’analyse des données single-cell, cherchent à préserver la géométrie locale des observations lors de leur représentation dans un espace de faible dimension. Malgré leur succès empirique, ces méthodes présentent plusieurs limites, notamment l’instabilité de l’optimisation, la difficulté d’interprétation des représentations obtenues et la nécessité de calibrer des paramètres de résolution. Notre objectif a été de proposer un cadre probabiliste et statistique permettant de mieux caractériser ces méthodes d’un point de vue théorique.

Dans le cadre de la thèse de H. van Assel (2021–2024), menée entre le LBMC et l’UMPA et co-encadrée avec A. Garivier (ENS de Lyon), nous avons proposé un modèle probabiliste génératif qui recouvre plusieurs méthodes classiques de réduction de dimension non linéaires. L’idée centrale consiste à supposer que les observations sont structurées suivant un graphe latent, et que la réduction de dimension vise à préserver ce graphe sous-jacent dans l’espace de faible dimension. Nous proposons pour cela un modèle de couplage de graphes latents de type champs de Markov aléatoires, reposant sur la minimisation d’une divergence de Kullback–Leibler entre les distributions a posteriori des graphes. Nous avons montré que l’ACP, les méthodes de type Stochastic Neighbor Embedding (SNE) et UMAP peuvent être retrouvées comme des instances particulières de ce modèle, associées à des lois a priori spécifiques sur les graphes. Dans le cas de SNE, ce cadre met également en évidence une dégénérescence de la loi induite par le graphe, qui apporte des éléments pour comprendre certains phénomènes observés empiriquement. Ce travail a été publié à *NeurIPS* [18]. Cette thèse a également permis d’établir une collaboration entre le LBMC et l’UMPA, créant de nouvelles interactions entre biologie et mathématiques sur le site de l’ENS de Lyon.

Méthodes non-linéaire de comparaison de distributions

Tests à noyaux pour l’analyse différentielle single-cell

Une question centrale de l’analyse des données en cellules uniques est la comparaison de l’expression des gènes entre différentes conditions. Les approches classiques comparent généralement des statistiques résumées des distributions, en particulier leurs moyennes. Les technologies single-cell donnant accès à la distribution complète de l’expression sur un grand nombre de cellules, nous nous sommes intéressés à des méthodes non paramétriques permettant de comparer directement ces distributions. Les méthodes à noyaux sont particulièrement adaptées à cette question puisqu’elles permettent des comparaisons non linéaires entre échantillons.

Dans le cadre de la thèse d’A. Ozier-Lafontaine (2020–2024, financement CIRIC, co-encadrement avec B. Michel, Nantes), nous avons développé un test non paramétrique qui s’appuie sur une méthode de classification supervisée. La statistique est solution d’un problème d’optimisation inspiré de l’analyse discriminante de Fisher à noyaux (KFDA, [3]), dont la résolution permet également d’identifier les axes discriminant les conditions testées. Notre méthode combine ainsi test statistique et représentation des observations. Notre procédure appartient à la famille des tests à noyaux, dont le plus connu est le Maximum Mean Discrepancy (MMD, [5]), qui compare l’espérance des représentants des distributions dans un espace de Hilbert à noyau reproduisant (RKHS). L’approche KFDA se distingue par la prise en compte de la structure de covariance des observations dans le RKHS, ce qui est particulièrement important pour prendre en compte la variabilité biologique des données single-cell. Bien que sa distribution asymptotique sous l’hypothèse nulle soit connue, son coût computationnel élevé avait fortement limité son utilisation. Nous avons développé une version efficace du test par approximation de Nyström, tout en garantissant le niveau du test.

Cette méthode a été publiée dans *Genome Biology* [11] et implémentée dans le package R/Python `ktest`. Nous l'avons appliquée à des données transcriptomiques produites dans l'équipe d'O. Gandrillon pour comparer des cellules différenciées et non différenciées, ainsi qu'à des données single-cell ChIP-seq obtenues en collaboration avec C. Vallot (Institut Curie), afin d'étudier les mécanismes épigénétiques associés à la résistance aux traitements dans le cancer du sein. Ce travail constitue également un exemple des liens que je cherche à développer entre statistique et IA : une question classique de test statistique est abordée à partir de représentations non linéaires des observations et d'un outil de classification supervisée, tout en conservant des garanties d'inférence statistique. La poursuite de ce travail est financée par le PEPR Santé Numérique AI4scMed. Nous avons développé une généralisation de la comparaison de deux populations à des traitements associés à un plan expérimental quelconque. Cette approche permet désormais de construire des tests à noyaux suivant une démarche de type ANOVA, mais portant sur des embeddings non linéaires des observations (cf. projet, travail en cours).

Réduction de dimension pour les processus ponctuels

L'analyse de données single-cell ChIP-seq a fait émerger de nouvelles questions méthodologiques combinant processus ponctuels, analyse fonctionnelle et réduction de dimension. Dans ces données, chaque cellule est caractérisée par un ensemble de coordonnées correspondant aux positions de sites de fixation d'un facteur de transcription ou de modifications de la chromatine, comme H3K27me3. Grâce à ma collaboration avec C. Vallot (Institut Curie), nous avons eu accès à ces données pour lesquelles peu de méthodes permettent de prendre en compte la nature spatiale des observations le long du génome. Avec A. Roche et V. Rivoirard, nous nous sommes intéressés à la construction d'une méthode de réduction de dimension adaptée à ces objets. Nous proposons de modéliser, pour chaque cellule i , l'ensemble des coordonnées par un processus ponctuel $N_i = (T_1^i, \dots, T_{n_i}^i)$, auquel est associée une mesure aléatoire Π_i . Notre objectif était de construire une analyse en composantes principales pour un ensemble de processus $N_1, \dots, N_n$, concept qui n'existait pas pour les mesures aléatoires. L'idée centrale consiste à caractériser chaque processus par sa fonction de répartition

$$F_i(t) = \sum_{T \in N^i} 1_{\{t < T\}},$$

puis à réaliser une ACP fonctionnelle sur ces fonctions. Ce plongement établit un pont entre mesures aléatoires, et en particulier processus ponctuels, et analyse fonctionnelle. Il permet de définir des mesures de covariance et des noyaux de covariance fonctionnels nécessaires à la construction d'une ACP.

Nous avons introduit la notion de mesure principale, équivalent des composantes principales pour les mesures aléatoires, et établi l'existence d'une décomposition de Karhunen–Loève pour ces objets. Le cadre proposé est non paramétrique et ne dépend pas de la loi des processus observés. Nous avons néanmoins pu le caractériser pour des modèles particuliers, notamment les processus de Poisson et de Hawkes. Pour étudier le comportement des éléments propres, nous avons montré que les fonctions propres de l'opérateur de covariance sont solutions d'une équation intégral-différentielle, que nous avons caractérisée pour ces deux classes de processus. Nous avons ensuite proposé une méthode d'inférence non paramétrique, implémentée dans le package R `pppca`. Initialement motivée par l'épigénétique single-cell, la méthode a également été appliquée à des données de sismologie, où les événements correspondent aux dates de tremblements de terre, et de neurosciences, où ils correspondent aux temps de potentiels d'action des neurones. Ce travail illustre ainsi comment une question issue des données single-cell peut conduire à un développement statistique de portée beaucoup plus générale. Il a été publié dans *Annals of Statistics* et ouvre plusieurs perspectives développées dans mon projet.

Étude du microenvironnement des tumeurs hypophysaires

Nos développements méthodologiques pour les données single-cell bénéficient d'une collaboration avec P. Bertolino au Centre de Recherche en Cancérologie de Lyon, dont l'équipe développe une recherche translationnelle sur les pathologies hypophysaires. Nous nous intéressons aux tumeurs neuroendocrines hypophysaires (PitNETs), et en particulier aux tumeurs gonadotropes, qui représentent environ 30% des PitNETs et restent dépourvues de traitement médical. Le microenvironnement tumoral apparaît comme un acteur important de leur progression, mais sa composition et les interactions entre cellules tumorales, immunitaires et stromales restent encore mal caractérisées. Notre collaboration vise à combiner approches expérimentales, données single-cell et transcriptomique spatiale pour mieux comprendre cette organisation.

Dans une première étude, nous avons montré qu'une sous-population de cellules immunitaires, les mastocytes, interagit avec les cellules endothéliales. En combinant approches expérimentales et analyses de données, nous avons mis en évidence leur rôle pro-tumoral et montré que leur distribution dans le tissu est associée à une vascularisation tumorale accrue. Ce travail a été publié dans *Neuro-Oncology* [6]. Nous avons ensuite initié une cartographie histologique à grande échelle qui nous a conduits à identifier les cellules folliculostellaires comme un nouvel acteur du microenvironnement tumoral hypophysaire. Sur une cohorte de plus de 50 patients, nos résultats indiquent que leur présence dans certaines régions tumorales pourrait contribuer au maintien d'un caractère bénin, peu prolifératif et bien différencié des tumeurs gonadotropes. Des données de séquençage en cellules uniques mettent également en évidence une hétérogénéité de ces populations, certaines exprimant des marqueurs de cellules souches dont le rôle reste à caractériser.

Un aspect central de cette collaboration concerne le développement de nouvelles méthodes pour l'analyse de données de transcriptomique spatiale Visium (10xGenomics). Cette technologie permet de mesurer l'expression génique directement dans le tissu tout en conservant l'information spatiale. Dans le cadre de l'ANR SpaceTranscriptomix, nous cherchons à exploiter cette information pour caractériser la structure spatiale des réseaux de communication entre cellules tumorales et cellules du microenvironnement. Deux thèses sont actuellement menées dans ce cadre (L. Attwood et B. Samson), portant respectivement sur la détection de gènes spatialement variables par des méthodes à noyaux et sur l'intégration de données d'imagerie pour l'analyse multimodale de la transcriptomique spatiale.

References

- [1] Ryad Belhakem, Franck Picard, Vincent Rivoirard, and Angelina Roche. Minimax estimation of functional principal components from noisy discretized functional data. *Scandinavian Journal of Statistics*, 2024.
- [2] Anna Bonnet, Claire Lacour, Franck Picard, and Vincent Rivoirard. Uniform deconvolution for poisson point processes. *Journal of Machine Learning Research*, 23(194):1–36, 2022.
- [3] Moulines Eric, Francis Bach, and Zaïd Harchaoui. Testing for homogeneity with kernel fisher discriminant analysis. In J. Platt, D. Koller, Y. Singer, and S. Roweis, editors, *Advances in Neural Information Processing Systems*, volume 20. Curran Associates, Inc., 2007.
- [4] Ilaria Frasson, Valentina Pirota, Sara N. Richter, and Filippo Doria. Multimeric g-quadruplexes: A review on their biological roles and targeting. *International Journal of Biological Macromolecules*, 204:89–102, 2022.
- [5] Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *J. Mach. Learn. Res.*, 13(null):723–773, March 2012.
- [6] Mirela-Diana Ilie, Álvaro Flores-Martínez, Marie Chanal, Maxime Lepetit, Benoit Samson, Ayoub Lehiani, Alexandre Vasiljevic, Laura Chinezu, Emmanuel Jouanneau, David Bernard, et al. Mast cells act as pro-angiogenic and pro-tumorigenic players in pituitary gonadotroph tumors. *Neuro-oncology*, page noaf241, 2025.
- [7] Stéphane Ivanoff, Franck Picard, and Vincent Rivoirard. Adaptive lasso and group-lasso for functional poisson regression. *Journal of Machine Learning Research*, 17(55):1–46, 2016.
- [8] H. Long, L. Zhang, M. Lv, Z. Wen, W. Zhang, X. Chen, P. Zhang, T. Li, L. Chang, C. Jin, G. Wu, X. Wang, F. Yang, J. Pei, P. Chen, R. Margueron, H. Deng, M. Zhu, and G. Li. H2A.Z facilitates licensing and activation of early replication origins. *Nature*, 577(7791):576–581, 01 2020.
- [9] M. I. Love, W. Huber, and S. Anders. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biol.*, 15(12):550, Dec 2014.
- [10] Florian Massip, Marc Laurent, Caroline Brossas, José Miguel Fernández-Justel, María Gómez, Marie-Noëlle Prioleau, Laurent Duret, and Franck Picard. Evolution of replication origins in vertebrate genomes: rapid turnover despite selective constraints. *Nucleic acids research*, 47(10):5114–5125, 2019.
- [11] A Ozier-Lafontaine, C Fourneaux, G Durif, P Arsenteva, C Vallot, O Gandrillon, S Gonin-Giraud, B Michel, and F Picard. Kernel-based testing for single-cell differential analysis. *Genome Biology*, 25(1):114, 2024.
- [12] S. Pepke, B. Wold, and A. Mortazavi. Computation for ChIP-seq and RNA-seq studies. *Nat. Methods*, 6(11 Suppl):22–32, Nov 2009.
- [13] F. Picard, J. C. Cadoret, B. Audit, A. Arneodo, A. Alberti, C. Battail, L. Duret, and M. N. Prioleau. The spatiotemporal program of DNA replication is associated with specific combinations of chromatin marks in human cells. *PLoS Genet.*, 10(5):e1004282, May 2014.
- [14] Jérémy Poulet-Benedetti, Caroline Tonnerre-Doncarli, Anne-Laure Valton, Marc Laurent, Marie Gérard, Natalja Barinova, Nikolaos Parisi, Florian Massip, Franck Picard, and Marie-Noëlle Prioleau. Dimeric g-quadruplex motifs-induced nfrs determine strong replication origins in vertebrates. *Nature Communications*, 14(1):4843, 2023.
- [15] A.-L. Valton, V. Hassan-Zadeh, I. Lema, N. Boggetto, P. Alberti, C. Saintome, J.-F. Riou, and M.-N. Prioleau. G4 motifs affect origin positioning and efficiency in two vertebrate replicators. *The EMBO Journal*, 33(7):732–746, February 2014.
- [16] A. L. Valton, V. Hassan-Zadeh, I. Lema, N. Boggetto, P. Alberti, C. Saintome, J. F. Riou, and M. N. Prioleau. G4 motifs affect origin positioning and efficiency in two vertebrate replicators. *EMBO J.*, 33(7):732–746, Apr 2014.
- [17] A.-L. Valton, F. Picard, P. Alberti, C. Saintomé, J.-F. Riou, and M.-N. Prioleau. G4 motifs are necessary but not sufficient for replication initiation in vertebrates. In *Eukaryotic DNA replication & Genome maintenance, Cold Spring Harbor Laboratory meeting*, page 6, 2015.
- [18] Hugues Van Assel, Thibault Espinasse, Julien Chiquet, and Franck Picard. A probabilistic graph coupling view of dimension reduction. *Advances in Neural Information Processing Systems*, 35:10696–10708, 2022.
- [19] S. Zreika, C. Fourneaux, E. Vallin, L. Modolo, R. Seraphin, A. Moussy, E. Ventre, M. Bouvier, A. Ozier-Lafontaine, A. Bonnaffoux, F. Picard, O. Gandrillon, and S. Gonin-Giraud. Evidence for close molecular proximity between reverting and undifferentiated cells. *BMC Biol*, 20(1):155, 07 2022.